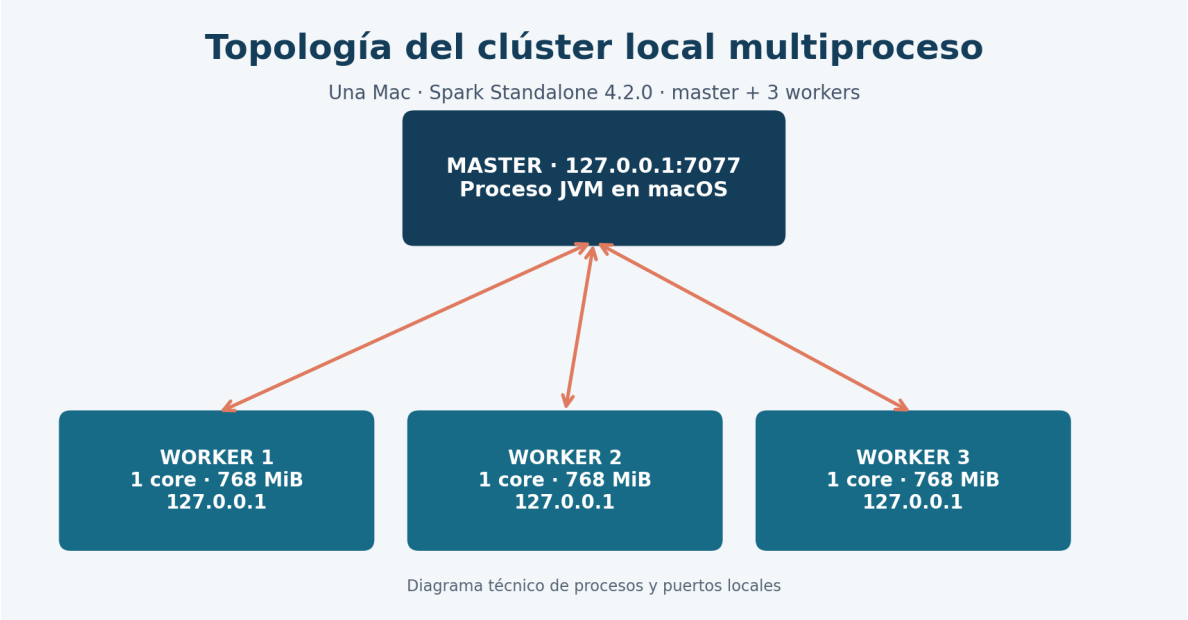
PRÁCTICA DE LABORATORIO

Clúster Spark local multiproceso

Análisis del mercado inmobiliario del Perú



ALUMNO	Hector Paolo Barazorda
CURSO	Minería de Datos
DOCENTE	Julio Vladimir Quispe Sota
UNIVERSIDAD	Universidad Nacional de San Antonio Abad del Cusco
ESCUELA PROFESIONAL	Ingeniería Informática y de Sistemas

Resumen ejecutivo

Esta práctica diseña un entorno Spark Standalone con procesos independientes en una sola computadora y aplica un flujo reproducible de análisis sobre dos archivos CSV inmobiliarios. La topología conserva los roles de un clúster real —master, driver y tres workers—, pero usa la interfaz loopback para evitar depender de equipos conectados a una red física.

500 000	59	147 143	94 364	36 681
REGISTROS TOTALES	COLUMNAS DE ORIGEN	REGISTROS SUR	REGISTROS NORTE	REGISTROS CUSCO

Resultados principales

El Norte alcanza una tasa de compra de 15,33 %, por encima del Sur (11,91 %). En alquiler ocurre lo contrario: el Sur registra 26,27 % y el Norte 21,49 %. En Cusco, la tasa de compra desciende desde 46,42 % para ratios de endeudamiento menores a 0,25 hasta 1,25 % para ratios iguales o superiores a 0,50.

Alcance de las cifras

Las cifras descriptivas incluidas en este documento fueron obtenidas mediante un recorrido secuencial fila a fila de los dos CSV, sin cargar el conjunto completo en pandas. El paquete incorpora guiones PySpark que reproducen las agregaciones en el clúster local multiproceso. No se presentan tiempos, métricas predictivas ni capturas de interfaces que no hayan sido medidos durante una ejecución real.

Objetivos

1) configurar una arquitectura local con procesos Spark independientes; 2) perfilar las macrorregiones Sur y Norte con una misma función; 3) comparar precios y tasas de cierre; 4) estudiar la decisión de compra o alquiler en Cusco; 5) dejar un protocolo de medición de escalabilidad con 1, 2 y 3 workers.

1. Arquitectura del laboratorio

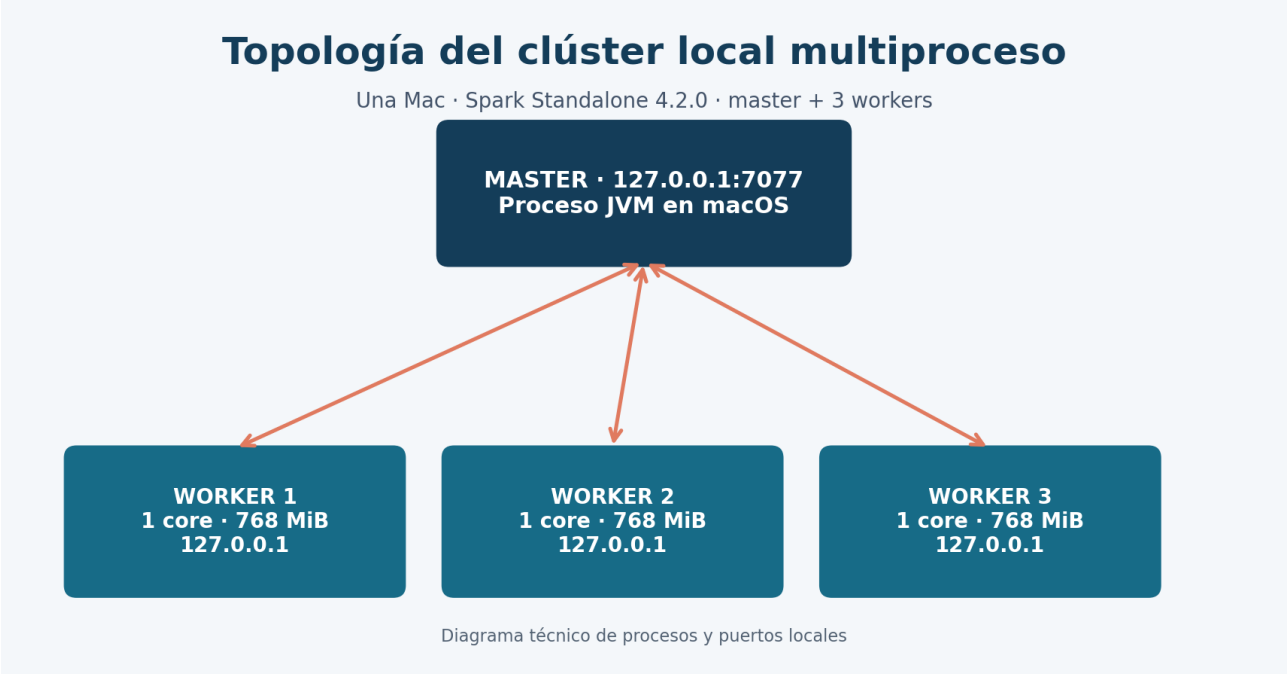


Figura 1. Topología lógica del laboratorio. Cada daemon mantiene PID, log, directorio de trabajo y puertos propios.

Componente	Dirección	Responsabilidad	Recursos propuestos
Master	127.0.0.1:7077	Registro de workers y planificación	Proceso JVM
Worker 1	RPC 7078 · UI 8081	Executor independiente	1 core · 768 MiB
Worker 2	RPC 7079 · UI 8082	Executor independiente	1 core · 768 MiB
Worker 3	RPC 7080 · UI 8083	Executor independiente	1 core · 768 MiB
Driver	Cliente local	Envía la aplicación al master	Python + PySpark

La separación por procesos es importante: no se reemplaza Spark por hilos Python ni por un único local[*]. El master administra tres workers Standalone y el driver se conecta con spark://127.0.0.1:7077. El uso exclusivo de loopback evita exponer servicios de Spark fuera del equipo.

2. Dataset y metodología

Los dos archivos contienen 500 000 registros y 59 variables. Cada fila representa la evaluación de un inmueble por parte de un hogar, con atributos del inmueble, entorno, perfil socioeconómico, condiciones financieras, comportamiento de búsqueda y desenlaces de compra o alquiler.

Bloque	Ejemplos	Uso analítico
Ubicación	departamento, ciudad, distrito	Macrorregión y comparación territorial
Inmueble	tipo, área, habitaciones, antigüedad	Oferta y heterogeneidad del producto
Precio	venta, precio/m², alquiler, mantenimiento	Nivel de mercado y asequibilidad
Hogar	ingreso, ahorros, deudas, score	Capacidad financiera
Decisión	probabilidades, compra, alquila	Tasas observadas y objetivos ML

Definición de macrorregiones

Sur: Puno, Cusco, Arequipa, Tacna, Moquegua, Apurímac y Ayacucho. Norte: La Libertad, Tumbes, Áncash, San Martín, Amazonas y Cajamarca. Los demás departamentos se clasifican como “Otro” y no participan en la comparación principal.

Flujo reproducible

Etapa	Implementación
Carga	Esquema explícito de 59 columnas; unión por nombre de ambas partes
Calidad	Conteos, nulos, duplicados, estadísticos y distribución categórica
EDA	groupBy, avg y percentile_approx; misma función para Sur y Norte
Cusco	Bucketizer y agregación de siete segmentaciones
Modelado	Pipeline MLlib con indexación, one-hot, escalamiento y regresión logística
Gráficos	Solo tablas agregadas pasan a memoria local para su representación

Se evita convertir el DataFrame completo a pandas. Esa frontera técnica es clave: Spark distribuye la preparación y la agregación; la librería gráfica recibe únicamente tablas pequeñas.

3. Análisis exploratorio · Sur

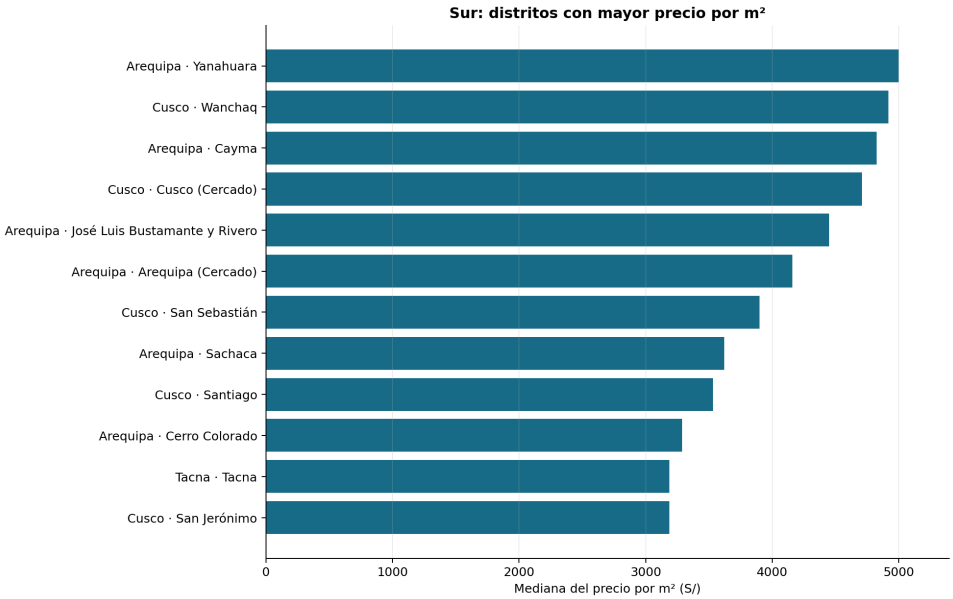


Figura 2. Doce distritos del Sur con mayor mediana de precio por m².

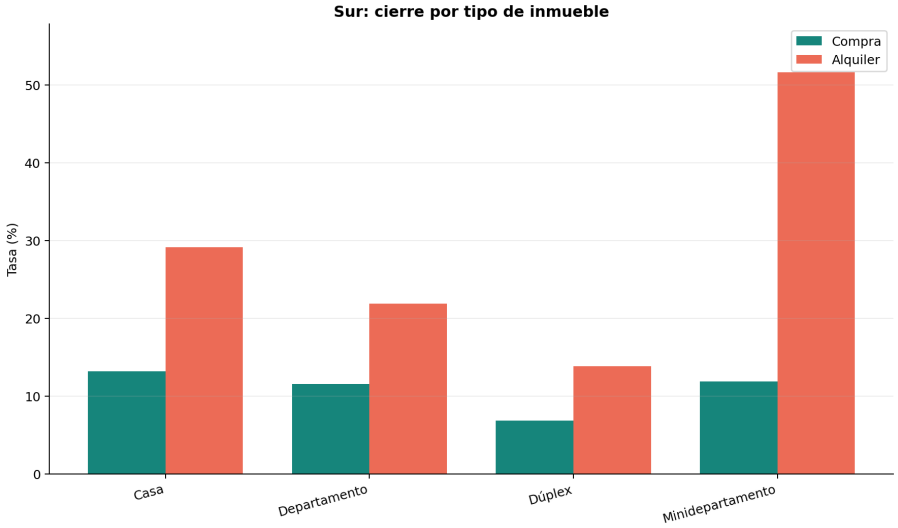


Figura 3. Tasas de compra y alquiler por tipo de inmueble en el Sur.

3.1 Lectura del Sur

Distrito	Registros	Mediana precio/m²
Arequipa · Yanahuara	6 558	S/ 5 000
Cusco · Wanchaq	7 784	S/ 4 917
Arequipa · Cayma	6 169	S/ 4 825
Cusco · Cusco (Cercado)	7 220	S/ 4 711
Arequipa · José Luis Bustamante y Rivero	5 675	S/ 4 450
Arequipa · Arequipa (Cercado)	5 308	S/ 4 159

Yanahuara encabeza el ranking con S/ 5 000 por m², seguida por Wanchaq con S/ 4 917 y Cayma con S/ 4 825. El patrón concentra los precios superiores en distritos urbanos consolidados de Arequipa y Cusco.

Tipo	Registros	Compra	Alquiler
Casa	66 119	13,21 %	29,16 %
Departamento	58 863	11,58 %	21,86 %
Dúplex	13 054	6,83 %	13,84 %
Minidepartamento	9 107	11,86 %	51,61 %

Las casas presentan la mayor tasa de compra del Sur (13,21 %). Los minidepartamentos destacan en alquiler con 51,61 %, más del doble de la tasa regional, lo que sugiere un producto orientado a ocupaciones flexibles o presupuestos acotados.

4. Análisis exploratorio · Norte

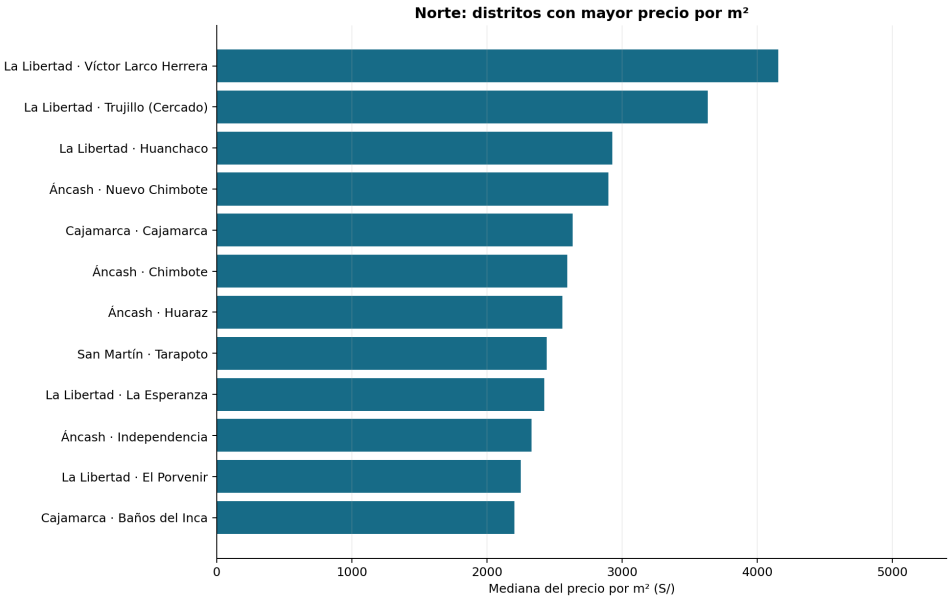


Figura 4. Doce distritos del Norte con mayor mediana de precio por m²; se mantiene la escala del Sur.

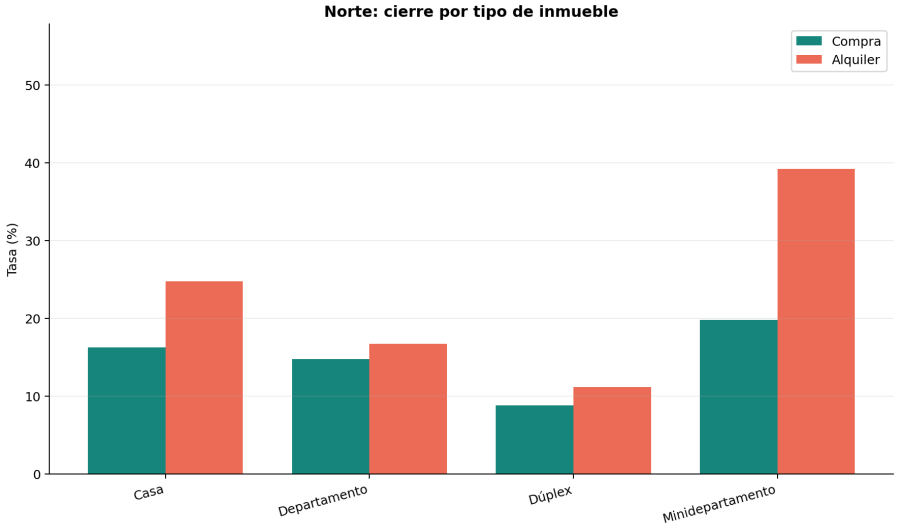


Figura 5. Tasas de compra y alquiler por tipo de inmueble en el Norte.

4.1 Lectura del Norte

Distrito	Registros	Mediana precio/m²
La Libertad · Víctor Larco Herrera	7 291	S/ 4 154
La Libertad · Trujillo (Cercado)	6 591	S/ 3 633
La Libertad · Huanchaco	4 260	S/ 2 929
Áncash · Nuevo Chimbote	4 916	S/ 2 900
Cajamarca · Cajamarca	6 577	S/ 2 633
Áncash · Chimbote	6 103	S/ 2 595

Víctor Larco Herrera registra la mayor mediana del Norte, S/ 4 154 por m². Trujillo (Cercado) ocupa el segundo lugar con S/ 3 633. Los valores máximos del Norte son inferiores a los tres primeros del Sur.

Tipo	Registros	Compra	Alquiler
Casa	55 292	16,26 %	24,76 %
Departamento	30 501	14,79 %	16,74 %
Dúplex	6 698	8,81 %	11,15 %
Minidepartamento	1 873	19,81 %	39,19 %

El minidepartamento muestra la tasa de compra más alta (19,81 %) y también la mayor tasa de alquiler (39,19 %). Las casas, que reúnen 55 292 registros, alcanzan 16,26 % de compra y 24,76 % de alquiler.

5. Comparación Sur–Norte

11,91 %	15,33 %	26,27 %	21,49 %
COMPRA SUR	COMPRA NORTE	ALQUILER SUR	ALQUILER NORTE

Indicador	Sur	Norte	Diferencia Norte − Sur
Registros	147 143	94 364	-52 779
Tasa de compra	11,91 %	15,33 %	+3,42 pp
Tasa de alquiler	26,27 %	21,49 %	−4,79 pp

Interpretación

El Norte exhibe mayor propensión observada a comprar, mientras que el Sur concentra una mayor propensión a alquilar. La diferencia no debe atribuirse a la ubicación por sí sola: el mix de inmuebles, los ingresos, el endeudamiento y la demanda turística pueden actuar como factores asociados.

Comparabilidad

Las tasas se calculan con la misma definición y la misma función de agregación. Los rankings distritales usan mediana, una medida menos sensible a valores extremos que el promedio. Los gráficos de precio comparten escala horizontal, lo que evita exagerar visualmente las diferencias regionales.

Implicancia operativa

Una estrategia comercial diferenciada podría priorizar productos de alquiler en el Sur —especialmente minidepartamentos— y reforzar el embudo de compra en el Norte. Antes de tomar decisiones, corresponde controlar simultáneamente las variables socioeconómicas y financieras mediante el pipeline predictivo.

6. Cusco · capacidad financiera y decisión

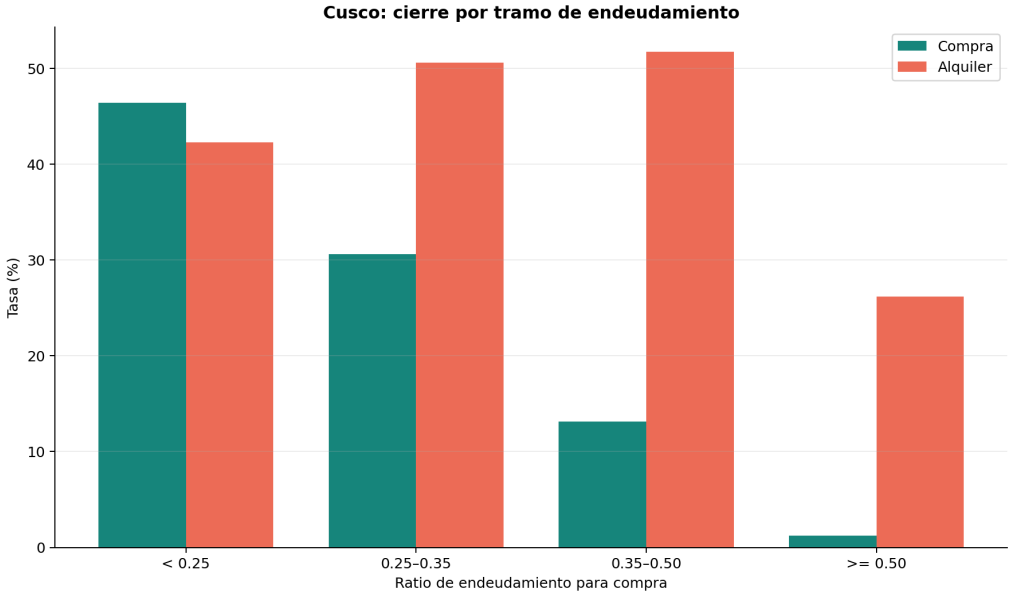


Figura 6. Tasas de cierre según el ratio de endeudamiento para compra.

Tramo de deuda	Registros	Compra	Alquiler
< 0.25	965	46,42 %	42,28 %
0.25–0.35	2 616	30,62 %	50,57 %
0.35–0.50	6 657	13,11 %	51,75 %
>= 0.50	26 443	1,25 %	26,20 %

La relación es monotónica para compra: al crecer el endeudamiento, cae la tasa observada. El tramo inferior a 0,25 compra en 46,42 % de los casos; el tramo desde 0,50 lo hace en apenas 1,25 %. En alquiler, los tramos intermedios superan 50 %, lo que es consistente con hogares que aún sostienen capacidad mensual pero no condiciones favorables para financiar una compra.

6.1 Cuota inicial y segmentaciones

Cubre cuota inicial	Registros	Compra	Alquiler
Sí	13 644	14,88 %	32,93 %
No	23 037	1,84 %	33,04 %

Cubrir la cuota inicial multiplica fuertemente la tasa observada de compra: 14,88 % frente a 1,84 %. La tasa de alquiler permanece prácticamente estable (32,93 % frente a 33,04 %), lo que distingue una barrera específica de acceso a la propiedad.

Segmentaciones reproducibles

El guion PySpark produce tablas separadas por tramo de endeudamiento, cobertura de cuota inicial, situación laboral, tipo de inmueble, motivo de búsqueda, número de integrantes y distrito. Cada tabla informa registros, tasa de compra y tasa de alquiler.

Criterio analítico

Los resultados describen asociación, no causalidad. La cuota inicial y el ratio de endeudamiento pueden estar relacionados con ingresos, ahorros, estabilidad laboral y elegibilidad crediticia. Por eso el siguiente paso es estimar modelos multivariados y evaluar su rendimiento fuera de la muestra de entrenamiento.

7. Flujo predictivo con Spark MLlib

Paso	Compra	Alquiler
Objetivo	compra	alquila
Partición	70 % entrenamiento / 30 % prueba · semilla 2026	Igual protocolo
Categóricas	Situación laboral, inmueble, motivo, distrito, vivienda actual, estado civil	Mismas variables
Numéricas	Deuda, cuota inicial, contado, visitas, integrantes, entorno	Incluye ratio alquiler/ingreso
Algoritmo	Regresión logística regularizada	Regresión logística regularizada
Evaluación	Área bajo ROC en prueba	Área bajo ROC en prueba

Prevención de fuga de información

Se excluyen prob_compra, prob_alquiler y el objetivo contrario. Incluir esas columnas inflaría artificialmente el rendimiento porque contienen información directa o derivada del desenlace.

Interpretación

El pipeline reporta los cinco coeficientes de mayor magnitud absoluta y sus odds ratios. Para variables numéricas estandarizadas, el odds ratio representa el cambio por una desviación estándar; para indicadores categóricos, compara la categoría codificada con la referencia. No se informa un AUC hasta ejecutar el entrenamiento y producir el archivo de métricas correspondiente.

8. Protocolo de escalabilidad

Escenario	Workers	Repeticiones	Resultado a registrar
Base · 500 mil filas	1, 2 y 3	1 calentamiento + 3 medidas	Mediana de segundos
Ampliado · 5 millones	1, 2 y 3	1 calentamiento + 3 medidas	Mediana de segundos

La medición debe mantener constantes el dataset, la consulta, las particiones y los recursos por worker. Con volúmenes pequeños, el costo de planificación, serialización y coordinación puede neutralizar el paralelismo. Por eso no se afirma aceleración sin observaciones temporales obtenidas bajo el protocolo.

9. Reproducibilidad

Orden	Acción	Comprobación
1	Instalar Java, Spark y Python; crear entorno	Versiones registradas
2	Iniciar master y tres workers locales	Procesos y puertos independientes
3	Ejecutar run_spark_analysis.py	Conteo 500 000 y 59 columnas de origen
4	Revisar resultados y gráficos	Agregados coherentes con el JSON base
5	Ejecutar run_scalability.py por escenario	Tres repeticiones y mediana
6	Regenerar este PDF	Documento y pruebas sin errores

Controles incluidos

Las pruebas unitarias validan la clasificación regional, los límites de tramos de deuda, la unicidad de las 59 columnas, el cálculo de tasas y medianas, y las reglas editoriales del informe. Los gráficos usan un backend no interactivo para funcionar en terminales sin sesión gráfica.

Limitaciones

El dataset es de carácter académico y no constituye una fuente oficial del mercado peruano. Los resultados son descriptivos; no establecen causalidad. La arquitectura local permite practicar la coordinación de Spark Standalone, pero todos los procesos comparten CPU, memoria y disco físicos. Las métricas de un despliegue en varias máquinas pueden diferir por red, almacenamiento y heterogeneidad del hardware.

10. Conclusiones

El laboratorio integra arquitectura, ingeniería de datos y análisis en un flujo coherente. La separación del master y tres workers conserva la mecánica operativa de Spark Standalone dentro de una sola Mac. Los agregados muestran perfiles regionales distintos: mayor compra en el Norte y mayor alquiler en el Sur. Cusco evidencia que el endeudamiento y la cobertura de la cuota inicial son señales especialmente relevantes para la decisión de compra.

La entrega queda preparada para ejecutar EDA, segmentaciones, modelos MLlib y mediciones controladas sin inventar resultados. El valor pedagógico está en conectar cada conclusión con una transformación reproducible y en distinguir con claridad lo calculado, lo medido y lo que todavía requiere ejecución.